

# 法律声明

■ 本课件包括演示文稿、示例、代码、题库、视频和声音等内容，北风网和讲师拥有完全知识产权；只限于善意学习者在本课程使用，不得在课程范围外向任何第三方散播。任何其他人或者机构不得盗版、复制、仿造其中的创意和内容，我们保留一切通过法律手段追究违反者的权利。

■ 课程详情请咨询

◆ 微信公众号：北风教育

◆ 官方网址：<http://www.ibeifeng.com/>



# 人工智能之机器学习




## 自适应提升算法 (AdaBoost)

主讲人：赵翌臣


上海育创网络科技有限公司




# AdaBoost直观理解




# AdaBoost直观理解





# AdaBoost直观理解




# AdaBoost直观理解



# AdaBoost直观理解





# AdaBoost直观理解







# AdaBoost直观理解



# 集成模型一览

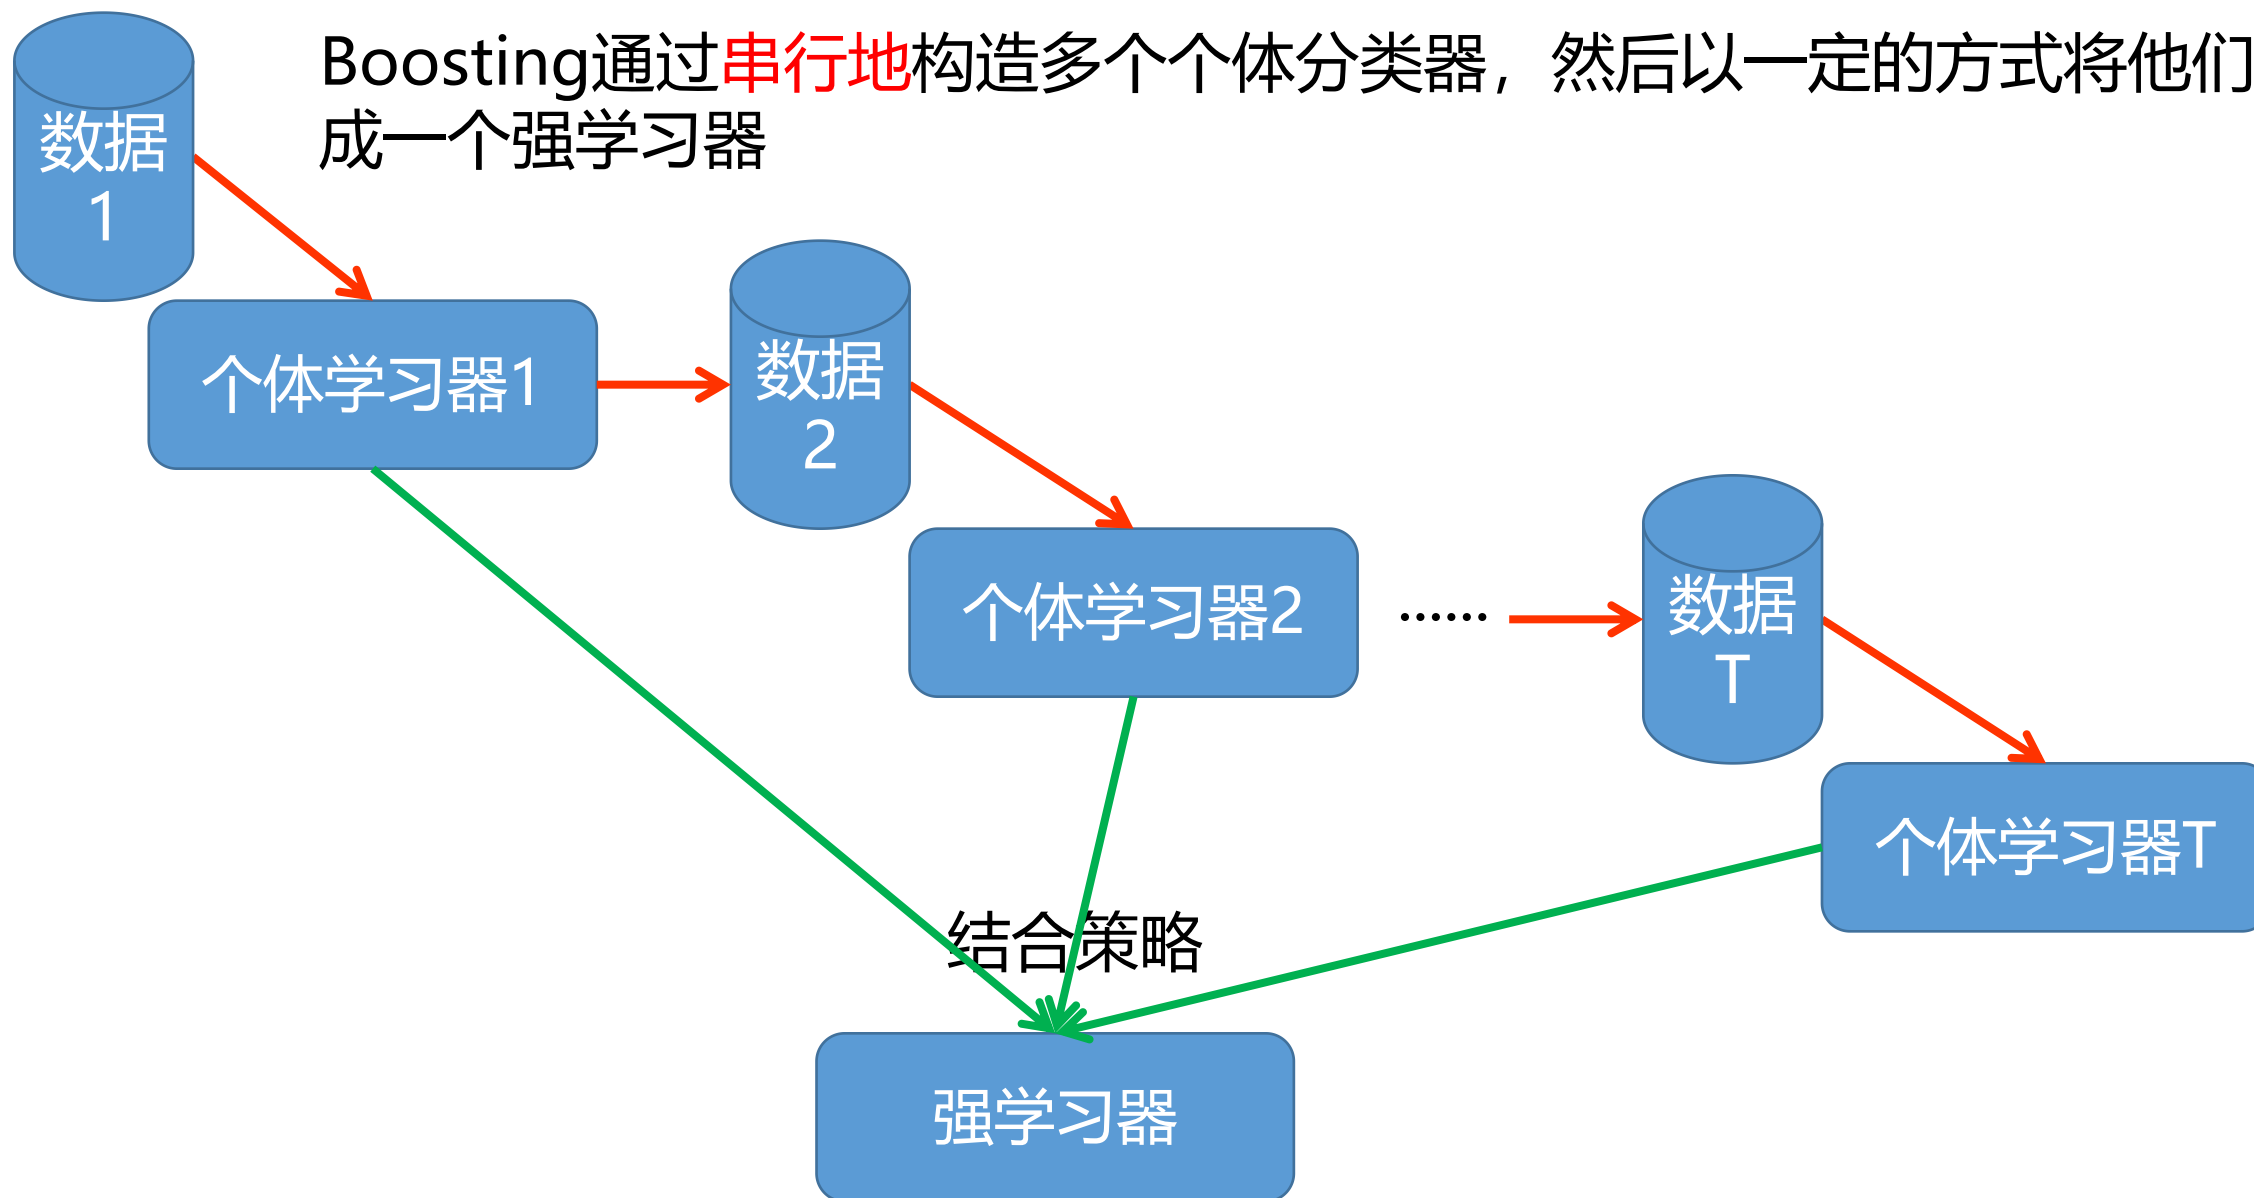


由于是抽象的，  
也可以叫思想

具体实现

# 集成学习——Boosting思想

Boosting通过**串行地**构造多个个体分类器，然后以一定的方式将他们组合成一个强学习器



# Boosting Methods

- Boosting is one of the most powerful learning ideas introduced in the last twenty years. It was originally designed for **classification** problems, but as will be seen in this chapter, it can profitably be **extended to regression** as well. The motivation for boosting was a procedure (程序) that combines the outputs of many “weak” classifiers to produce a powerful “committee (委员会) .” From this perspective (视角) boosting bears (具有) a resemblance (相似性) to bagging and other committee-based approaches . **However** we shall see that the connection is at best (顶多) superficial (浅显的) and that boosting is fundamentally different.
- We begin by describing the most popular boosting algorithm due to Freund and Schapire called “AdaBoost.M1.”

# AdaBoost (1995) 思想

## ■ 介绍

- ◆ AdaBoost, 是 “Adaptive Boosting” (自适应增强) 的缩写, 是一种机器学习方法, 由Yoav Freund和Robert Schapire于1995年提出。

## ■ 思想

- ◆ 前面的模型对训练集预测后, 在每个样本上都会产生一个不同损失, AdaBoost会为每个样本更新权重, 损失越大, **样本权重**越大, 下一个学习器会更加 “**关注**” 这些权重大的样本; 得到m个模型后, AdaBoost会根据每个模型的表现, 给每个模型**设置一个系数, 带权叠加**得到最终集成模型

# AdaBoost的两个问题

## ■ 两个问题

- ◆ 如何得到若干个个体学习器？
- ◆ 如何将个体学习器进行结合？

# AdaBoost分类

- 输入：训练集为

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}, \quad y \in \{-1, +1\}$$

- 训练弱学习器M个。输出：最终的强学习器G(x)

- 1) 初始化样本集权重为

$$D_1 = (w_{11}, w_{12}, \dots, w_{1N}) \quad w_{1i} = \frac{1}{N}, \quad i = 1, 2, \dots, N$$

- 2) 对于m=1,2,...,M:

- ◆ a) 使用具有权值分布D<sub>m</sub>的训练数据来训练模型，得到弱学习器G<sub>m</sub>(x)

抽象

- ◆ b) 计算G<sub>m</sub>(x)的分类误差率

$$e_m = \sum_{i=1}^N w_{mi} I(G_m(x) \neq y_i)$$

# AdaBoost分类

## ◆ c) 计算弱学习器的系数

$$\alpha_m = \frac{1}{2} \log \frac{1 - e_m}{e_m}$$

## ◆ d) 更新训练集中样本的权重


- ▶ 分类正确的, ?? 权重; 分类错误的?? 权重

## ■ 3) 构建基本学习器的线性组合:

$$f(x) = \sum_{i=1}^M \text{learning\_rate} * \alpha_m G_m(x)$$

## ■ 4) 最终学习器为:

$$G(x) = \text{sign}(f(x))$$





# AdaBoost分类\*

---

## Algorithm 10.1 *AdaBoost.M1*.

---

1. Initialize the observation weights  $w_i = 1/N$ ,  $i = 1, 2, \dots, N$ .
  2. For  $m = 1$  to  $M$ :
    - (a) Fit a classifier  $G_m(x)$  to the training data using weights  $w_i$ .
    - (b) Compute
 
$$\text{err}_m = \frac{\sum_{i=1}^N w_i I(y_i \neq G_m(x_i))}{\sum_{i=1}^N w_i}.$$
    - (c) Compute  $\alpha_m = \log((1 - \text{err}_m)/\text{err}_m)$ .
    - (d) Set  $w_i \leftarrow w_i \cdot \exp[\alpha_m \cdot I(y_i \neq G_m(x_i))]$ ,  $i = 1, 2, \dots, N$ .
  3. Output  $G(x) = \text{sign} \left[ \sum_{m=1}^M \alpha_m G_m(x) \right]$ .
-

## 编程4——基于Boosting的分类

**例 8.1** 给定如表 8.1 所示训练数据. 假设弱分类器由  $x < v$  或  $x > v$  产生, 其阈值  $v$  使该分类器在训练数据集上分类误差率最低. 试用 AdaBoost 算法学习一个强分类器.

表 8.1 训练数据表

| 序号  | 1 | 2 | 3 | 4  | 5  | 6  | 7 | 8 | 9 | 10 |
|-----|---|---|---|----|----|----|---|---|---|----|
| $x$ | 0 | 1 | 2 | 3  | 4  | 5  | 6 | 7 | 8 | 9  |
| $y$ | 1 | 1 | 1 | -1 | -1 | -1 | 1 | 1 | 1 | -1 |



# AdaBoost回归\*

- 输入：训练集为

$$T = \{(x_1, y_1), (x_2, y_2), \dots, (x_N, y_N)\}, \quad y \in R$$

- 训练弱学习器M个。输出：最终的强学习器G (x)

- 1) 初始化训练集权重为

$$D_1 = (w_{11}, w_{12}, \dots, w_{1N}), \quad w_{1i} = \frac{1}{N}, i = 1, 2, \dots, N$$

- 2) 对于m=1,2,...,M:

- ◆ a) 使用具有权值分布D<sub>m</sub>的训练数据来训练模型，得到弱学习器G<sub>m</sub>(x)
- ◆ b) 计算f<sub>m</sub>(x)的回归误差率

$$e_m = \sum_{i=1}^N w_{mi} \frac{(y_i - G_m)^2}{E_m^2}$$

$$E_m = \max |y_i - G_m|, i = 1, 2, \dots, N$$

# AdaBoost回归\*

- ◆ c) 计算 $\alpha_m$  (用于计算弱学习器的系数)

$$\alpha_m = \frac{e_m}{1 - e_m}$$


- ◆ d) 更新训练集中样本的权重

- ▶ 误差小的, 降低权重, 误差大的增加权重

## ■ 3) 最终学习器

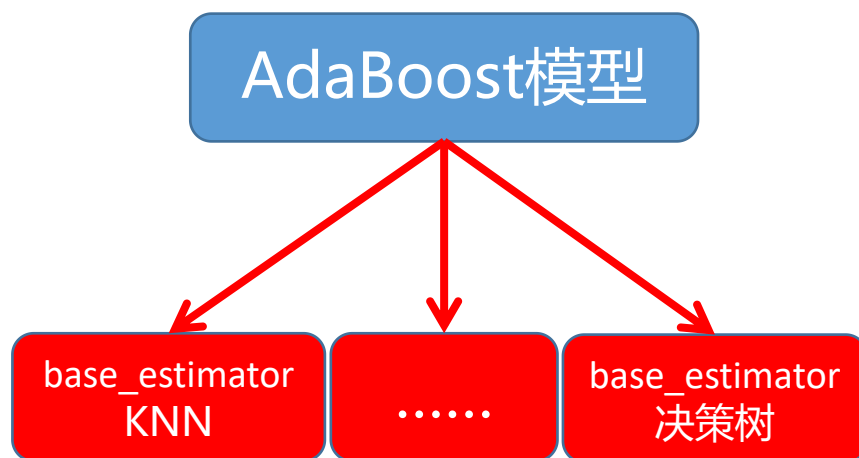
- ◆ 先对弱学习器进行加权, 取中位数, 再组成最终模型

$$G(x) = \sum_{i=1}^M \text{learning\_rate} * (\ln \frac{1}{\alpha_m}) g(x), \text{ 其中 } g(x) \text{ 是所有 } \alpha_m G_m(x), m = 1, 2, \dots, M \text{ 的中位数}$$



# AdaBoost in sklearn

- `class sklearn.ensemble.AdaBoostClassifier(base_estimator=None, n_estimators=50, learning_rate=1.0, algorithm=' SAMME.R' , random_state=None)`
- `class sklearn.ensemble.AdaBoostRegressor(base_estimator=None, n_estimators=50, learning_rate=1.0, loss=' linear' , random_state=None)`



# AdaBoost思想的优缺点

## ■ 优点:

- ◆ 可以使用各种回归分类模型来构建弱学习器，非常灵活
- ◆ Sklearn中对AdaBoost的实现是从带权学习视角出发的，思想朴素，易于理解
- ◆ 用正则、学习率、步长和控制迭代次数可以一定程度防止发生过拟合

## ■ 缺点:

- ◆ 对异常样本敏感，异常样本在迭代中可能会获得较高的权重，影响最终预测准确性。
- ◆ 带权学习视角下AdaBoost做分类时无非是前向分步学习视角下的一个特例，不支持自定义损失函数

# AdaBoost小结

- AdaBoost属于boosting思想，他是1995年由Freund等人提出
- 提升树
  - ◆ AdaBoost思想结合决策树的基学习器，就得到提升树模型。提升树做分类时，基学习器选CART分类树；回归时选CART回归树
- 两个视角
  - ◆ 带权学习视角、前向分布学习视角
- 前向分步学习的说明
  - ◆ 在前向分步学习视角下，当提升树的损失函数是平方损失和指数损失时，优化是简单的，但对一般损失函数而言优化难度大，即没有通用的求解方案
  - ◆ 因此2001年，Friedman提出了一个通用方案——梯度提升，起名为GBDT

# 编程——基于Boosting的回归

**例 8.2** 已知如表 8.2 所示的训练数据， $x$  的取值范围为区间 $[0.5,10.5]$ ， $y$  的取值范围为区间 $[5.0,10.0]$ ，学习这个回归问题的提升树模型，考虑只用树桩作为基函数。

表 8.2 训练数据表

| $x_i$ | 1    | 2    | 3    | 4    | 5    | 6    | 7    | 8    | 9    | 10   |
|-------|------|------|------|------|------|------|------|------|------|------|
| $y_i$ | 5.56 | 5.70 | 5.91 | 6.40 | 6.80 | 7.05 | 8.90 | 8.70 | 9.00 | 9.05 |



并行地训练多颗回归树，对样本进行预测时，所有回归树同时预测，取均值作为输出



# 编程——基于Boosting的分类

**例 8.1** 给定如表 8.1 所示训练数据. 假设弱分类器由  $x < v$  或  $x > v$  产生, 其阈值  $v$  使该分类器在训练数据集上分类误差率最低. 试用 AdaBoost 算法学习一个强分类器.

表 8.1 训练数据表

| 序号  | 1 | 2 | 3 | 4  | 5  | 6  | 7 | 8 | 9 | 10 |
|-----|---|---|---|----|----|----|---|---|---|----|
| $x$ | 0 | 1 | 2 | 3  | 4  | 5  | 6 | 7 | 8 | 9  |
| $y$ | 1 | 1 | 1 | -1 | -1 | -1 | 1 | 1 | 1 | -1 |



# 编程——AdaBoost综合案例之森林植被类型预测

## ■ 数据集：

◆ <https://archive.ics.uci.edu/ml/datasets/coverture>

## ■ 解释：

◆ 该数据集记录了美国科罗拉多州不同地块的森林植被类型。每个样本包含了描述每块土地的若干特征，包括海拔、坡度、到水源的距离、遮阳情况和土壤类型，并且随同给出了地块的已知森林植被类型。我们需要总共54 个特征中的其余各项来预测森林植被类型



|                            |                      |                       |        |                     |            |
|----------------------------|----------------------|-----------------------|--------|---------------------|------------|
| Data Set Characteristics:  | Multivariate         | Number of Instances:  | 581012 | Area:               | Life       |
| Attribute Characteristics: | Categorical, Integer | Number of Attributes: | 54     | Date Donated        | 1998-08-01 |
| Associated Tasks:          | Classification       | Missing Values?       | No     | Number of Web Hits: | 185453     |

# 编程——AdaBoost回归案例之共享单车租赁数量预测



- This dataset contains the hourly and daily count of rental bikes between years 2011 and 2012 in Capital bikeshare system with the corresponding weather and seasonal information.

◆ 数据下载 <http://archive.ics.uci.edu/ml/datasets/Bike+Sharing+Dataset>

|                            |               |                       |       |                     |            |
|----------------------------|---------------|-----------------------|-------|---------------------|------------|
| Data Set Characteristics:  | Univariate    | Number of Instances:  | 17389 | Area:               | Social     |
| Attribute Characteristics: | Integer, Real | Number of Attributes: | 16    | Date Donated        | 2013-12-20 |
| Associated Tasks:          | Regression    | Missing Values?       | N/A   | Number of Web Hits: | 232895     |






# THANK YOU

上海育创网络科技有限公司

# 决策树参数 (回归树为例)

- Suppose first that we have a partition into  $J$  regions  $R_1, R_2, \dots, R_J$ , and we model the response as a constant  $\gamma_j$  in each region :

$$f(x) = \sum_{j=1}^J \gamma_j I(x \in R_j)$$



## 决策树参数（回归树为例）

- Regression and classification trees are discussed in detail in Section 9.2. They partition the space of all joint predictor variable values into disjoint regions  $R_j$ ,  $j = 1, 2, \dots, J$ , as represented by the terminal nodes of the tree. A constant  $\gamma_j$  is assigned to each such region and the predictive rule is

$$x \in R_j \Rightarrow f(x) = \gamma_j$$


- Thus a tree can be formally expressed as

$$f(x) = \sum_{j=1}^J \gamma_j I(x \in R_j)$$

# AdaBoost的前向分步学习视角

$$\min \sum_{i=1}^N L(y_i, f(x))$$

- 考虑下 ,  $L = \exp(-y_i f(x))$
- 如果 $y_i$ 是+1 , 那 $f(x)$ 越大越好
- 如果 $y_i$ 是 -1 , 那 $f(x)$ 越小越好
- 最终模型 :  $G(x) = \text{sign}(f(x))$





# AdaBoost的前向分步学习视角\*

---

**Algorithm 10.2** *Forward Stagewise Additive Modeling.*

---

1. Initialize  $f_0(x) = 0$ .

2. For  $m = 1$  to  $M$ :

(a) Compute

$$(\beta_m, \gamma_m) = \arg \min_{\beta, \gamma} \sum_{i=1}^N L(y_i, f_{m-1}(x_i) + \beta b(x_i; \gamma)).$$

(b) Set  $f_m(x) = f_{m-1}(x) + \beta_m b(x; \gamma_m)$ .

---